

# Prognozowanie Wynagrodzeń Pracowniczych (Salary Predictor)

Projekt końcowy: Analiza predykcyjna i wdrożenie modelu (FastAPI + Streamlit)

1. Cel i zakres projektu Celem niniejszego projektu jest zbudowanie modelu uczenia maszynowego zdolnego do prognozowania miesięcznego dochodu (MonthlyIncome) na podstawie cech demograficznych i zawodowych pracowników. Projekt obejmuje pełen cykl życia modelu: od czyszczenia danych, przez AutoML, aż po wdrożenie produkcyjne.
2. Źródła danych i ograniczenia (Data Sourcing) Wstępnym założeniem projektu było wzbogacenie danych o czynniki makroekonomiczne, takie jak historyczna stopa procentowa oraz wskaźniki inflacji z określonych lat, aby zbadać ich wpływ na dynamikę płac.

Ważna uwaga (Lessons Learned): Podjęto próbę powiązania zbioru danych z zewnętrznymi wskaźnikami ekonomicznymi. Jednak ze względu na:

- Brak miarodajnych i spójnych danych czasowych w pierwotnym zbiorze,
- Anonimizację dat zatrudnienia uniemożliwiającą precyzyjne dopasowanie do kalendarza ekonomicznego,

zdecydowano się ograniczyć model do wewnętrznych parametrów organizacji. Podejście to pozwoliło na zbudowanie bardziej stabilnego modelu opartego na mierzalnych cechach stanowiskowych, co w końcowej fazie zaowocowało wysokim współczynnikiem .

## 3. Wykorzystane technologie

Backend: FastAPI (Python) Frontend: Streamlit ML Engine: PyCaret / Scikit-Learn Data Validation: Pandera / Pydantic

4. Interpretowalność Modelu (XAI) W projekcie wykorzystano bibliotekę SHAP (SHapley Additive exPlanations). Pozwala ona na precyzyjne zrozumienie, które cechy (np. lata doświadczenia, poziom stanowiska) miały największy wpływ na konkretną prognozę wynagrodzenia. Dzięki temu model jest w pełni transparentny dla użytkownika końcowego.

## Wczytanie danych

Wczytujemy dane z datasetu kagglehub. Dane przechodzą bez api. Zapisują się one lokalnie u użytkownika

Sukces! Wczytano dane z: C:\Users\Ryszard\.cache\kagglehub\datasets\pavansubhasht\ibm-hr-analytics-attrition-dataset\versions\1\WA\_Fn-UseC\_-HR-Employee-Attrition.csv  
Rozmiar danych: (1470, 35)

|      | Age | Attrition | BusinessTravel    | DailyRate | Department             | DistanceFromHome | Education | EducationalLevel |
|------|-----|-----------|-------------------|-----------|------------------------|------------------|-----------|------------------|
| 42   | 26  | Yes       | Travel_Rarely     | 1357      | Research & Development | 25               | 3         | Life             |
| 76   | 35  | No        | Travel_Rarely     | 776       | Sales                  | 1                | 4         | M                |
| 1380 | 35  | No        | Travel_Rarely     | 682       | Sales                  | 18               | 4         |                  |
| 252  | 29  | No        | Travel_Rarely     | 665       | Research & Development | 15               | 3         | Life             |
| 388  | 42  | No        | Travel_Rarely     | 201       | Research & Development | 1                | 4         | Life             |
| 1206 | 26  | No        | Non-Travel        | 786       | Research & Development | 7                | 3         |                  |
| 547  | 42  | Yes       | Travel_Frequently | 933       | Research & Development | 19               | 3         |                  |
| 35   | 43  | No        | Travel_Rarely     | 1273      | Research & Development | 2                | 2         |                  |
| 31   | 44  | No        | Travel_Rarely     | 1459      | Research & Development | 10               | 4         |                  |
| 320  | 27  | No        | Travel_Rarely     | 1377      | Sales                  | 2                | 3         | Life             |
| 1108 | 35  | No        | Travel_Rarely     | 992       | Research & Development | 1                | 3         |                  |
| 1025 | 24  | No        | Travel_Rarely     | 1476      | Sales                  | 4                | 1         |                  |
| 694  | 33  | No        | Travel_Rarely     | 1069      | Research & Development | 1                | 3         | Life             |
| 1082 | 23  | No        | Travel_Rarely     | 507       | Research & Development | 20               | 1         | Life             |
| 1177 | 50  | No        | Travel_Rarely     | 813       | Research & Development | 17               | 5         | Life             |
| 28   | 44  | No        | Travel_Rarely     | 477       | Research & Development | 7                | 4         |                  |
| 18   | 53  | No        | Travel_Rarely     | 1219      | Sales                  | 2                | 4         | Life             |
| 260  | 32  | No        | Travel_Frequently | 1311      | Research & Development | 7                | 3         | Life             |
| 935  | 32  | No        | Travel_Rarely     | 604       | Sales                  | 8                | 3         |                  |
| 679  | 31  | No        | Non-Travel        | 1188      | Sales                  | 20               | 2         | M                |

20 rows × 35 columns

# Wypełniamy brakujące wartości

W procesie przygotowania danych kluczowym krokiem jest obsługa brakujących wartości (NaN), które powstały w wyniku błędów zapisu lub niepoprawnego formatowania typów danych.

Zdecydowano się na imputację medianą dla wszystkich cech numerycznych z następujących powodów:

**Realizm biznesowy:** Wartości takie jak wiek (Age) czy stawka (DailyRate) równe 0 są niemożliwe w kontekście zatrudnienia i wprowadzałyby model w błąd.

**Odporność na anomalie:** Mediana, w przeciwieństwie do średniej, lepiej reprezentuje typowego pracownika w przypadku wystąpienia skrajnych wynagrodzeń lub stażu pracy.

**Spójność typów:** Po uzupełnieniu braków wszystkie kolumny zostały rzutowane na typ `int64` (liczby całkowite), co optymalizuje proces trenowania modelu i jest zgodne z formatem wejściowym API.

## Dla wartości tekstowych zostało zastosowane wypełnienie za pomocą dominanty

## Inżynieria Cech (Feature Engineering) i Mapowanie

W celu poprawnego działania modelu regresji oraz zapewnienia spójności z serwerem FastAPI, dane wejściowe zostały poddane transformacji numerycznej.

Cechy kategoryczne o charakterze binarnym (Tak/Nie) zostały skonwertowane na format numeryczny (0 lub 1). Pozwala to modelowi na matematyczną interpretację stanów logicznych. Kolumny Attrition, Over18, OverTime dla wartości Yes są mapowane na True, pozostałe na False.

Cecha BusinessTravel zawiera naturalną hierarchię (intensywność podróży), dlatego zastosowano mapowanie porządkowe zamiast kodowania One-Hot. Dzięki temu model zachowuje informację o stopniu natężenia danej cechy.

- brak podróży - 0
- podróże rzadkie - 1
- podróże częste - 2

`int64`

|      | Age | Attrition | BusinessTravel | DailyRate | Department             | DistanceFromHome | Education | Educatio |
|------|-----|-----------|----------------|-----------|------------------------|------------------|-----------|----------|
| 597  | 42  | False     | 1              | 932       | Research & Development | 1                | 2         | Life Sc  |
| 137  | 39  | False     | 1              | 1329      | Sales                  | 4                | 4         | Life Sc  |
| 1398 | 33  | False     | 2              | 1303      | Research & Development | 7                | 2         | Life Sc  |
| 1029 | 40  | False     | 0              | 663       | Research & Development | 9                | 4         |          |
| 735  | 48  | False     | 1              | 277       | Research & Development | 6                | 3         | Life Sc  |
| 1069 | 28  | False     | 1              | 1423      | Research & Development | 1                | 3         | Life Sc  |
| 988  | 41  | False     | 2              | 1200      | Research & Development | 22               | 3         | Life Sc  |
| 15   | 29  | False     | 1              | 1389      | Research & Development | 21               | 4         | Life Sc  |
| 706  | 40  | True      | 0              | 1479      | Sales                  | 24               | 3         | Life Sc  |
| 179  | 38  | False     | 1              | 1380      | Research & Development | 9                | 2         | Life Sc  |
| 1331 | 48  | False     | 1              | 1224      | Research & Development | 10               | 3         | Life Sc  |
| 1156 | 40  | False     | 1              | 884       | Research & Development | 15               | 3         | Life Sc  |
| 1405 | 31  | False     | 0              | 697       | Research & Development | 10               | 3         | M        |
| 371  | 29  | False     | 1              | 1283      | Research & Development | 23               | 3         | Life Sc  |
| 364  | 37  | False     | 1              | 921       | Research & Development | 10               | 3         | M        |
| 1057 | 29  | True      | 2              | 115       | Sales                  | 13               | 3         | Ter<br>I |
| 390  | 43  | False     | 1              | 982       | Research & Development | 12               | 3         | Life Sc  |
| 258  | 51  | False     | 1              | 833       | Research & Development | 1                | 3         | Life Sc  |
| 638  | 25  | False     | 1              | 583       | Sales                  | 4                | 1         | Mar      |
| 654  | 39  | False     | 1              | 1383      | Human Resources        | 2                | 3         | Life Sc  |

20 rows × 35 columns

# Rygorystyczna Walidacja Schematu (Data Validation)

Aby zapewnić integralność danych przesyłanych do modelu uczenia maszynowego oraz zminimalizować ryzyko błędów typu schema drift, wdrożono walidację przy użyciu biblioteki Pandera.

Charakterystyka Schematu Zdefiniowany obiekt DataFrameSchema pełni rolę kontraktu technicznego dla zbioru danych:

- Wymuszanie Typów (Static Typing): Każda z 35 kolumn ma przypisany ścisły typ (np. `pa.Int`, `pa.String`, `pa.Float`), co zapobiega błędom obliczeniowym w silniku PyCaret.
- Parametr `strict=True`: Gwarantuje, że zbiór danych zawiera tylko i wyłącznie zdefiniowane kolumny. Każda nadmiarowa kolumna zostanie odrzucona, co chroni model przed nieprzewidzianym wpływem cech zewnętrznych.
- Parametr `coerce=True`: Włącza automatyczną konwersję typów. Jeśli kolumna numeryczna została wczytana jako tekst, Pandera spróbuje ją "naprawić" przed walidacją finalną.
- Integralność (`nullable=False`): Wszystkie kluczowe cechy są wymagane. Dzięki wcześniejszej imputacji medianą mamy pewność, że zbiór jest kompletny.

Obsługa błędów W przypadku wykrycia niezgodności (np. brak kolumny `MonthlyIncome` lub błędny format `JobRole`), walidacja przerwie proces, rzucając wyjątek `SchemaError`, co uniemożliwia trenowanie modelu na uszkodzonych danych.

Dane `df` są poprawne

## Analiza Korelacji (Correlation Analysis)

Przed przystąpieniem do budowy modelu przeprowadzono analizę współczynnika korelacji Pearsona w celu zidentyfikowania najsilniejszych predyktorów dla zmiennej celu (`MonthlyIncome`).

Cel: Zrozumienie, które parametry pracownika (staż, wiek, poziom stanowiska) najsilniej wpływają na wysokość wynagrodzenia.  
Interpretacja: Wysokie wartości dodatnie wskazują na silną zależność proporcjonalną (wzrost cechy = wzrost płacy), natomiast wartości bliskie zeru sugerują cechy nieistotne statystycznie dla tego konkretnego modelu.

Najsilniejsze korelacje z wynagrodzeniem:

|                         |          |
|-------------------------|----------|
| MonthlyIncome           | 1.000000 |
| JobLevel                | 0.950300 |
| TotalWorkingYears       | 0.772893 |
| YearsAtCompany          | 0.514285 |
| Age                     | 0.497855 |
| YearsInCurrentRole      | 0.363818 |
| YearsSinceLastPromotion | 0.344978 |
| YearsWithCurrManager    | 0.344079 |
| NumCompaniesWorked      | 0.149515 |
| Education               | 0.094961 |

Name: MonthlyIncome, dtype: float64

## Przygotowanie Zbioru Treningowego i Kodowanie (Encoding)

W celu umożliwienia matematycznej analizy danych przez model, przeprowadzono transformację cech kategorycznych oraz podział zbioru na dane uczące i testowe.

### Selekcja Cech (Feature Selection)

Z procesu modelowania usunięto kolumny stałe lub nieistotne statystycznie (tzw. zero-variance predictors), takie jak EmployeeCount, Over18 oraz StandardHours. Usunięcie cech o zerowej zmienności zapobiega problemom z osobliwością macierzy w niektórych algorytmach.

### One-Hot Encoding (OHE)

Zastosowano technikę One-Hot Encoding dla pozostałych cech tekstowych (np. Department, EducationField, JobRole).

- Mechanizm: Każda unikalna kategoria zostaje przekształcona w osobną kolumnę binarną (0 lub 1).
- Parametr drop\_first=True: Zastosowano tzw. dummy encoding, który usuwa pierwszą wygenerowaną kolumnę dla każdej cechy. Zapobiega to wystąpieniu zjawiska współliniowości (multicollinearity), znanego jako pułapka zmiennej fikcyjnej (Dummy Variable Trap).

## Trenowanie Modelu i Ewaluacja Wyników (Model Training & Evaluation)

Po zakodowaniu cech kategorycznych do postaci numerycznej (One-Hot Encoding), przystąpiono do budowy modelu bazowego opartego na algorytmie Random Forest Regressor.

## Dlaczego Random Forest?

Wybrano algorytm lasów losowych (Random Forest), ponieważ:

- Odporność na nieliniowość: Skutecznie wyłapuje złożone zależności między cechami (np. wpływ wieku i stażu na zarobki nie zawsze jest liniowy).
- Brak wymagań co do skalowania: W przeciwieństwie do regresji liniowej, lasy losowe nie wymagają normalizacji danych (np. StandardScaler), co upraszcza proces wdrożenia w FastAPI.

## Metryki Sukcesu

Do oceny jakości prognoz płacowych wykorzystano dwa kluczowe wskaźniki:

- Współczynnik Determinacji ( $R^2$ ): Informuje, jaki procent zmienności płac został wyjaśniony przez model. Wynik bliski 1.0 oznaczałby model idealny, podczas gdy wartości powyżej 0.7-0.8 są uznawane za bardzo dobre w danych kadrowych.
- Średni Błąd Bezwzględny (MAE): Wyrażony w konkretnej walucie (USD). Mówi nam, o ile średnio "myli się" model w dolarach przy każdej prognozie. Jest to metryka najbardziej zrozumiała dla biznesu (np. "Nasz model myli się średnio o 150 USD").

--- SUKCES ---

Wynik  $R^2$ : 0.9439

Średni błąd: 824.61 USD

## Wypełnienie brakujących wartości zerami

## Sprawdzamy, które cechy model uznał za najważniejsze (Feature Importance)


TOP 5 najważniejszych czynników wpływających na płacę:

|                           |          |
|---------------------------|----------|
| JobLevel                  | 0.927605 |
| JobRole_Research Director | 0.010632 |
| TotalWorkingYears         | 0.009959 |
| JobRole_Manager           | 0.005583 |
| MonthlyRate               | 0.004518 |
| dtype: float64            |          |

## Wniosek

"Struktura płac w organizacji jest silnie hierarchiczna – poziom stanowiska (JobLevel) determinuje

wynagrodzenie w ponad 92%, przy czym specyficzne role jak Research Director czy Manager stanowią dodatkowe, istotne korekty".



## Interpretacja wykresu SHAP (Summary Plot)



Wykres ten łączy ważność cech z ich wpływem na wynik. Każda kropka to jeden pracownik z Twojego zbioru danych.

Oś pionowa (y): Ranking cech od najważniejszej (na górze) do najmniej istotnej. U Ciebie króluje JobLevel.

Oś pozioma (x): Wpływ na płacę (SHAP value).

-Punkty po prawej stronie zera to cechy, które podnoszą przewidywaną pensję.

-Punkty po lewej stronie zera to cechy, które obniżają przewidywaną pensję.

Kolory (skala od niebieskiego do czerwonego): Wartość danej cechy.

-Czerwony: Wysoka wartość (np. wysoki staż, wysoki szczebel).

- Niebieski: Niska wartość (np. początkujący pracownik).


Kluczowe wnioski z modelu:

- Dominacja JobLevel: Widzimy grubą czerwoną linię daleko po prawej stronie. Oznacza to, że przejście na wyższy poziom stanowiska drastycznie i jednoznacznie zwiększa pensję (najsilniejszy predyktor).

- Wpływ ról (Research Director / Manager): Czerwone kropki po prawej stronie przy tych kategoriach pokazują, że sam fakt pełnienia tych funkcji (wartość 1 w kodowaniu one-hot) daje wyraźną „premię” do wynagrodzenia względem innych ról.

- TotalWorkingYears: Zauważysz gradient kolorów – im bardziej „czerwony” staż pracy (więcej lat), tym bardziej punkty przesuwają się w prawo. Doświadczenie buduje wartość pracownika w sposób liniowy i stabilny.

"Model zidentyfikował, że struktura płac w organizacji jest silnie zhierarchizowana, gdzie poziom stanowiska (JobLevel) determinuje ponad 80% zmienności wynagrodzenia, wyprzedzając znacząco staż pracy czy wiek pracownika."



1. **Skuteczność i Precyzja Modelu (Business Value)** Zbudowany model regresji (Random Forest) osiągnął bardzo wysoką precyzję, tłumacząc aż 94,38% zmienności wynagrodzeń ( ). Średni błąd przewidywania (MAE) wynosi jedynie 824 USD, co przy szerokich widełkach płacowych w korporacji pozwala na rzetelne planowanie budżetu oraz identyfikację osób niedoszacowanych płacowo (anomaly detection).
2. **Kluczowe Determinanty Płacy (Insights)** Analiza ważności cech (Feature Importance) wykazała, że struktura wynagrodzeń w badanym zbiorze jest silnie sformalizowana. Największy wpływ na pensję ma JobLevel (poziom stanowiska), co sugeruje, że awanse pionowe są głównym motorem wzrostu zarobków, wyprzedzając znacząco staż pracy ogólny czy wiek pracownika.
3. **Świadome Zarządzanie Jakością Danych (Data Integrity)** W procesie przygotowania danych podjęto kluczowe decyzje inżynierskie: zidentyfikowano i uzupełniono braki w zmiennej YearsWithCurrManager (użycie mediany), przeprowadzono mapowanie zmiennych porządkowych (BusinessTravel) oraz kodowanie binarne cech takich jak OverTime czy Attrition. Usunięcie szumu informacyjnego (np. stałych wartości Over18) pozwoliło na uzyskanie stabilnego i wiarygodnego modelu.

## Etap 1: Analiza porównawcza wybranych algorytmów (Manual Benchmarking)

W tej sekcji przeprowadzamy kontrolowany eksperyment na trzech wybranych architekturach modeli: Random Forest, Linear Regression oraz LightGBM.

- Cel: Zrozumienie, jak różne podejścia (liniowe vs. drzewiaste) radzą sobie z naszym zbiorem danych.
- Procedura: Dla każdego modelu przeprowadzana jest walidacja krzyżowa (Cross-Validation), a średnie wyniki są agregowane w tabeli zbiorczej. Pozwala to na stabilną ocenę błędu bez ryzyka przeuczenia na pojedynczym podziale danych.

| model        | MAE      | MSE          | RMSE      | R2     | RMSLE  | MAPE   |
|--------------|----------|--------------|-----------|--------|--------|--------|
| REG_RF       | 799.2889 | 1036544.1740 | 1018.1081 | 0.9529 | 0.1805 | 0.1409 |
| REG_LR       | 921.2540 | 1387104.5578 | 1177.7540 | 0.9370 | 0.2180 | 0.1613 |
| REG_LIGHTGBM | 860.3190 | 1166053.0896 | 1079.8394 | 0.9470 | 0.1982 | 0.1529 |

Porównanie Modelów - Sortowalne Wizualnie

## Etap 2: Automatyczny wybór i eksport modelu produkcyjnego (AutoML Selection)

Po wstępnej analizie wykorzystujemy funkcję `compare_models()`, aby przeszukać pełną przestrzeń dostępnych algorytmów regresji.

- Kryterium wyboru: Współczynnik determinacji ( $R^2$ ) - dążymy do maksymalizacji wyjaśnionej wariancji płać.
- Automatyzacja: PyCaret automatycznie trenuje, testuje i sortuje modele, zwracając obiekt `best_model`.
- Persystencja: Wybrany model jest serializowany do pliku `.pkl` w katalogu `data/` za pomocą parametrów zdefiniowanych w `settings`, co zapewnia gotowość do natychmiastowego użycia przez serwer FastAPI.

|                 | Model                           | MAE       | MSE           | RMSE      | I |
|-----------------|---------------------------------|-----------|---------------|-----------|---|
| <b>rf</b>       | Random Forest Regressor         | 770.7447  | 1043398.7725  | 1018.1651 | ( |
| <b>gbr</b>      | Gradient Boosting Regressor     | 787.7230  | 1061491.0227  | 1026.1934 | ( |
| <b>et</b>       | Extra Trees Regressor           | 807.4598  | 1123663.5234  | 1057.6995 | ( |
| <b>lightgbm</b> | Light Gradient Boosting Machine | 810.8652  | 1134226.0189  | 1062.7615 | ( |
| <b>llar</b>     | Lasso Least Angle Regression    | 859.2710  | 1243747.3924  | 1113.7614 | ( |
| <b>lasso</b>    | Lasso Regression                | 859.2817  | 1243758.6452  | 1113.7664 | ( |
| <b>ridge</b>    | Ridge Regression                | 860.8385  | 1248148.1524  | 1115.7110 | ( |
| <b>lr</b>       | Linear Regression               | 861.9890  | 1249356.4199  | 1116.3356 | ( |
| <b>ada</b>      | AdaBoost Regressor              | 1034.8150 | 1650788.5143  | 1282.7932 | ( |
| <b>dt</b>       | Decision Tree Regressor         | 1027.7167 | 1950081.9342  | 1392.4796 | ( |
| <b>br</b>       | Bayesian Ridge                  | 1135.1106 | 3362447.3152  | 1476.7409 | ( |
| <b>en</b>       | Elastic Net                     | 1384.0662 | 3528924.0336  | 1861.8327 | ( |
| <b>omp</b>      | Orthogonal Matching Pursuit     | 2172.1476 | 8607389.9393  | 2912.5291 | ( |
| <b>huber</b>    | Huber Regressor                 | 2252.5775 | 9589431.4652  | 3070.3541 | ( |
| <b>dummy</b>    | Dummy Regressor                 | 3523.3675 | 21332899.3129 | 4603.2320 | - |
| <b>knn</b>      | K Neighbors Regressor           | 3874.6910 | 26360621.8859 | 5115.3609 | - |

|     | Model                   | MAE                | MSE                               | RMSE                | I |
|-----|-------------------------|--------------------|-----------------------------------|---------------------|---|
| par | Passive                 |                    |                                   |                     |   |
|     | Aggressive<br>Regressor | 5053.7461          | 41641066.2866                     | 6395.5382           | - |
| lar | Least                   |                    |                                   |                     |   |
|     | Angle<br>Regression     | 7173517429576.2969 | 1944525490512914861982220288.0000 | 13944632867559.9551 | - |

## 🏆 Ranking Algorytmów Regresji Płac (AutoML)

|                 | Model                           | MAE       | MSE           | RMSE      |
|-----------------|---------------------------------|-----------|---------------|-----------|
| <b>rf</b>       | Random Forest Regressor         | 770.7447  | 1043398.7725  | 1018.1651 |
| <b>gbr</b>      | Gradient Boosting Regressor     | 787.7230  | 1061491.0227  | 1026.1934 |
| <b>et</b>       | Extra Trees Regressor           | 807.4598  | 1123663.5234  | 1057.6995 |
| <b>lightgbm</b> | Light Gradient Boosting Machine | 810.8652  | 1134226.0189  | 1062.7615 |
| <b>llar</b>     | Lasso Least Angle Regression    | 859.2710  | 1243747.3924  | 1113.7614 |
| <b>lasso</b>    | Lasso Regression                | 859.2817  | 1243758.6452  | 1113.7664 |
| <b>ridge</b>    | Ridge Regression                | 860.8385  | 1248148.1524  | 1115.7110 |
| <b>lr</b>       | Linear Regression               | 861.9890  | 1249356.4199  | 1116.3356 |
| <b>ada</b>      | AdaBoost Regressor              | 1034.8150 | 1650788.5143  | 1282.7932 |
| <b>dt</b>       | Decision Tree Regressor         | 1027.7167 | 1950081.9342  | 1392.4796 |
| <b>br</b>       | Bayesian Ridge                  | 1135.1106 | 3362447.3152  | 1476.7409 |
| <b>en</b>       | Elastic Net                     | 1384.0662 | 3528924.0336  | 1861.8327 |
| <b>omp</b>      | Orthogonal Matching Pursuit     | 2172.1476 | 8607389.9393  | 2912.5291 |
| <b>huber</b>    | Huber Regressor                 | 2252.5775 | 9589431.4652  | 3070.3541 |
| <b>dummy</b>    | Dummy Regressor                 | 3523.3675 | 21332899.3129 | 4603.2320 |
| <b>knn</b>      | K Neighbors Regressor           | 3874.6910 | 26360621.8859 | 5115.3609 |

|            | Model                        | MAE                | MSE                               | RMSE                |
|------------|------------------------------|--------------------|-----------------------------------|---------------------|
| <b>par</b> | Passive Aggressive Regressor | 5053.7461          | 41641066.2866                     | 6395.5382           |
|            | Least Angle Regression       | 7173517429576.2969 | 1944525490512914861982220288.0000 | 13944632867559.9551 |

## Eksport Modelu i Konfiguracji (Deployment Ready)

Ostatnim krokiem jest utrwalenie wyników pracy w folderze data/, aby zapewnić pełną operacyjność aplikacji webowej. Proces ten obejmuje dwa kluczowe elementy: binarny model predykcyjny oraz metadane konfiguracyjne.

### Persystencja Modelu ML (.pkl)

Wykorzystano funkcję `save_model`, która serializuje wybrany algorytm (Random Forest) wraz z całym potokiem przetwarzania (pipeline).

- Integracja: Ścieżka zapisu jest pobierana dynamicznie z `settings.MODEL_NAME`, co eliminuje błędy manualne przy wdrażaniu.
- Format: Plik `.pkl` zawiera zoptymalizowane wagi modelu, gotowe do natychmiastowego ładowania przez bibliotekę `Joblib` lub `PyCaret`.

### Eksport Wartości Domyślnych (.json)

W celu zapewnienia stabilności API, wygenerowano plik `model_defaults.json` zawierający mediany i mody wyliczone na zbiorze treningowym.

- Fail-safe: W przypadku, gdy użytkownik w interfejsie Streamlit pominie opcjonalne pole, system automatycznie podstawia statystycznie bezpieczną wartość z tego pliku.
- Spójność: Dzięki temu podejściu, prognoza zawsze opiera się na danych o tej samej strukturze, na której model był trenowany.



Najlepszy model to: Random Forest Regressor z  $R^2 = 0.9488$

Transformation Pipeline and Model Successfully Saved



Model został zapisany jako: `E:\od_zera_do_ai\pyt\projekt_przewidywanie_płac\data\final_salary_model.pkl`

## Podsumowanie i wnioski (Conclusion)

Stabilność modelu wewnętrznego: Model oparty na parametrach organizacji (poziom stanowiska, staż, wydajność) osiągnął wysoką precyzję, co sugeruje, że struktura płac w badanym przedsiębiorstwie jest spójna i przewidywalna. Wpływ otoczenia makroekonomicznego (Refleksja): Choć obecny model operuje na danych statycznych, w warunkach realnej gospodarki kluczowymi determinantami siły nabywczej wynagrodzeń są:

- Inflacja i M2: Rosnąca podaż pieniądza (M2) oraz inflacja (CPI) powodują presję płacową. Model "produkcyjny" w długim terminie powinien uwzględniać coroczną waloryzację o te wskaźniki.
  - Stopy procentowe: Ich wysokość wpływa na koszty finansowania firm, co pośrednio może limitować budżety na podwyżki w sektorach kapitałochłonnych.
- Rekomendacja datowania danych: Dla przyszłych iteracji projektu kluczowe jest wprowadzenie precyzyjnego datowania rekordów (timestamp). Pozwoli to na:
- Przeliczenie wynagrodzeń na walutę stałą (skorygowaną o inflację).
  - Zastosowanie analizy szeregów czasowych, uwzględniającej cykle koniunkturalne.

Zastosowanie SHAP: Analiza SHAP wykazała, że [tu wpisz najważniejszą cechę, np. TotalWorkingYears] jest najsilniejszym predyktorem płacy, co potwierdza rynkową zasadę premiowania doświadczenia zawodowego.



Budowanie czystego pliku HTML...



Sukces! Plik 'notebook.slides.html' został naprawiony.



Teraz otwórz ten plik RĘCZNIE w przeglądarce (dwuklik na plik).